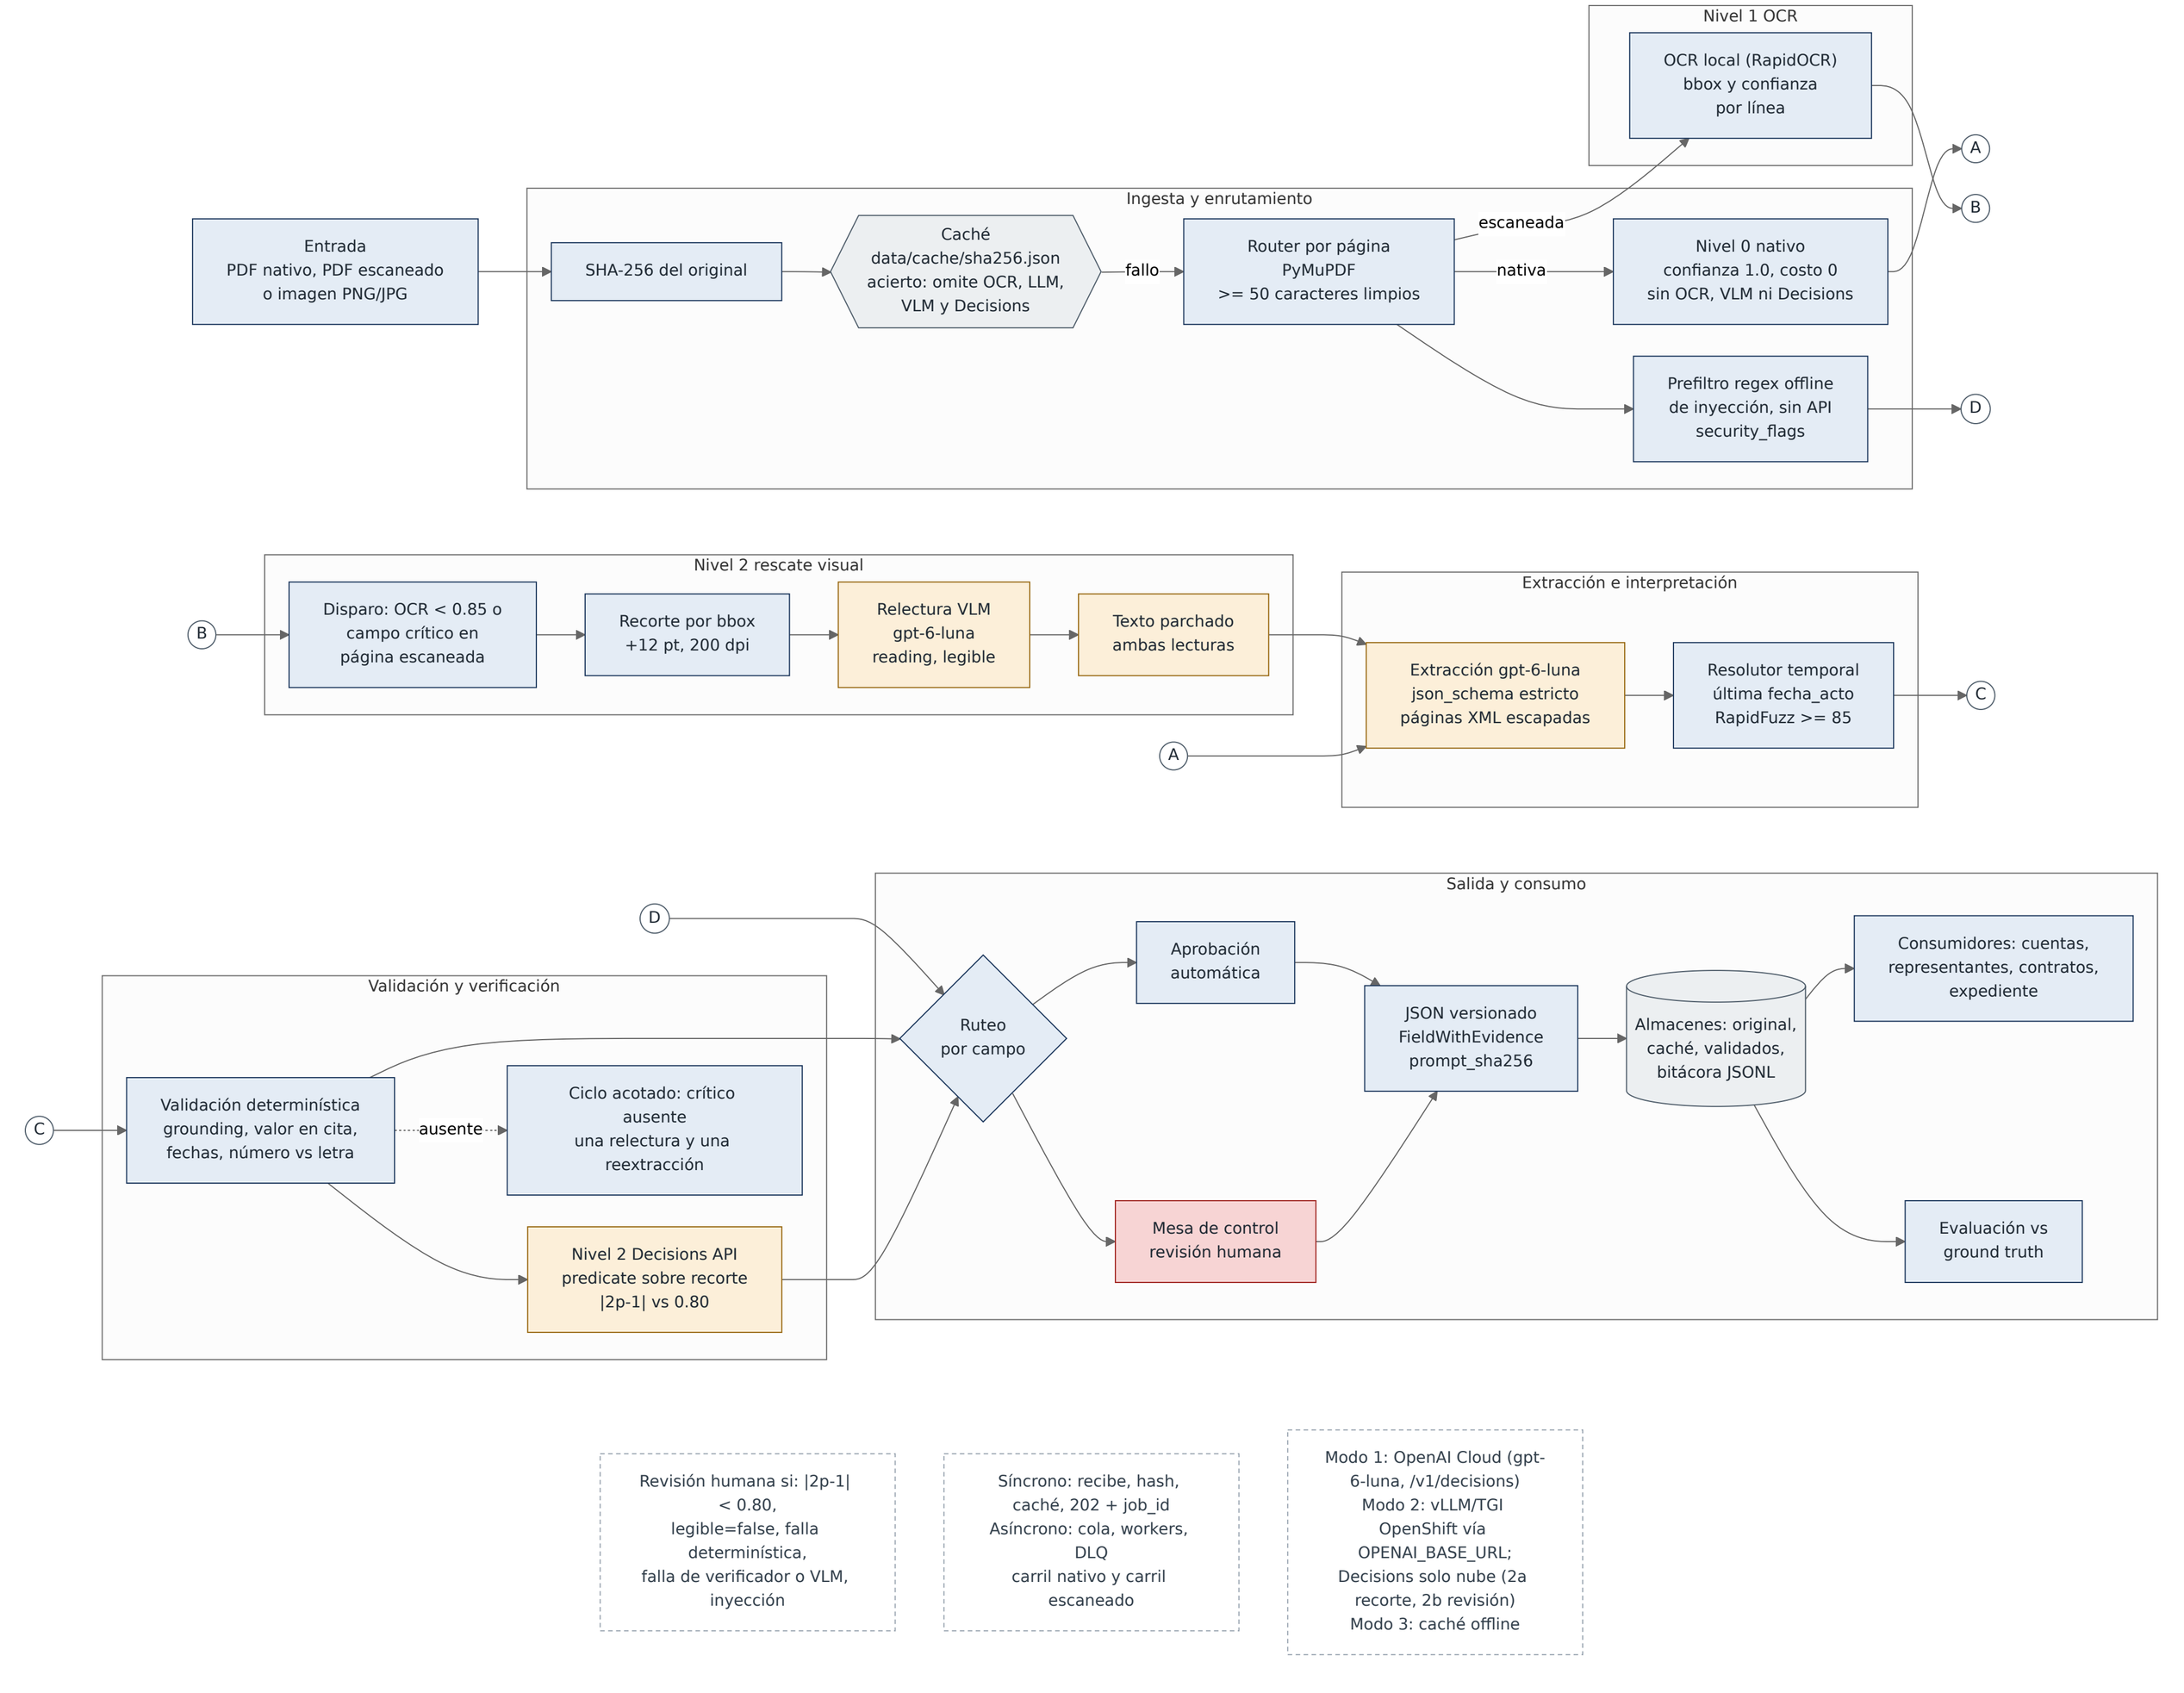

Nivel 1 OCR
OCR local (RapidOCR)
bbox y confianza
por línea
Ingesta y enrutamiento
Entrada
PDF nativo, PDF escaneado
o imagen PNG/JPG
SHA-256 del original
Caché
data/cache/sha256.json
acierto: omite OCR, LLM,
VLM y Decisions
fallo
Router por página
PyMuPDF
>= 50 caracteres limpios
escaneada
nativa
Nivel 0 nativo
confianza 1.0, costo 0
sin OCR, VLM ni Decisions
Prefiltro regex offline
de inyección, sin API
security_flags
A
B
D
Nivel 2 rescate visual
B
Disparo: OCR < 0.85 o
campo crítico en
página escaneada
Recorte por bbox
+12 pt, 200 dpi
Relectura VLM
gpt-6-luna
reading, legible
Texto parchado
ambas lecturas
Extracción e interpretación
A
Extracción gpt-6-luna
json_schema estricto
páginas XML escapadas
Resolutor temporal
última fecha_acto
RapidFuzz >= 85
C
Salida y consumo
D
Ruteo
por campo
Aprobación
automática
Mesa de control
revisión humana
JSON versionado
FieldWithEvidence
prompt_sha256
Almacenes: original,
caché, validados,
bitácora JSONL
Consumidores: cuentas,
representantes, contratos,
expediente
Evaluación vs
ground truth
Validación y verificación
C
Validación determinística
grounding, valor en cita,
fechas, número vs letra
ausente
Ciclo acotado: crítico
ausente
una relectura y una
reextracción
Nivel 2 Decisions API
predicate sobre recorte
|2p-1| vs 0.80
Revisión humana si: |2p-1|
< 0.80,
legible=false, falla
determinística,
falla de verificador o VLM,
inyección
Síncrono: recibe, hash,
caché, 202 + job_id
Asíncrono: cola, workers,
DLQ
carril nativo y carril
escaneado
Modo 1: OpenAI Cloud (gpt-
6-luna, /v1/decisions)
Modo 2: vLLM/TGI
OpenShift vía
OPENAI_BASE_URL;
Decisions solo nube (2a
recorte, 2b revisión)
Modo 3: caché offline