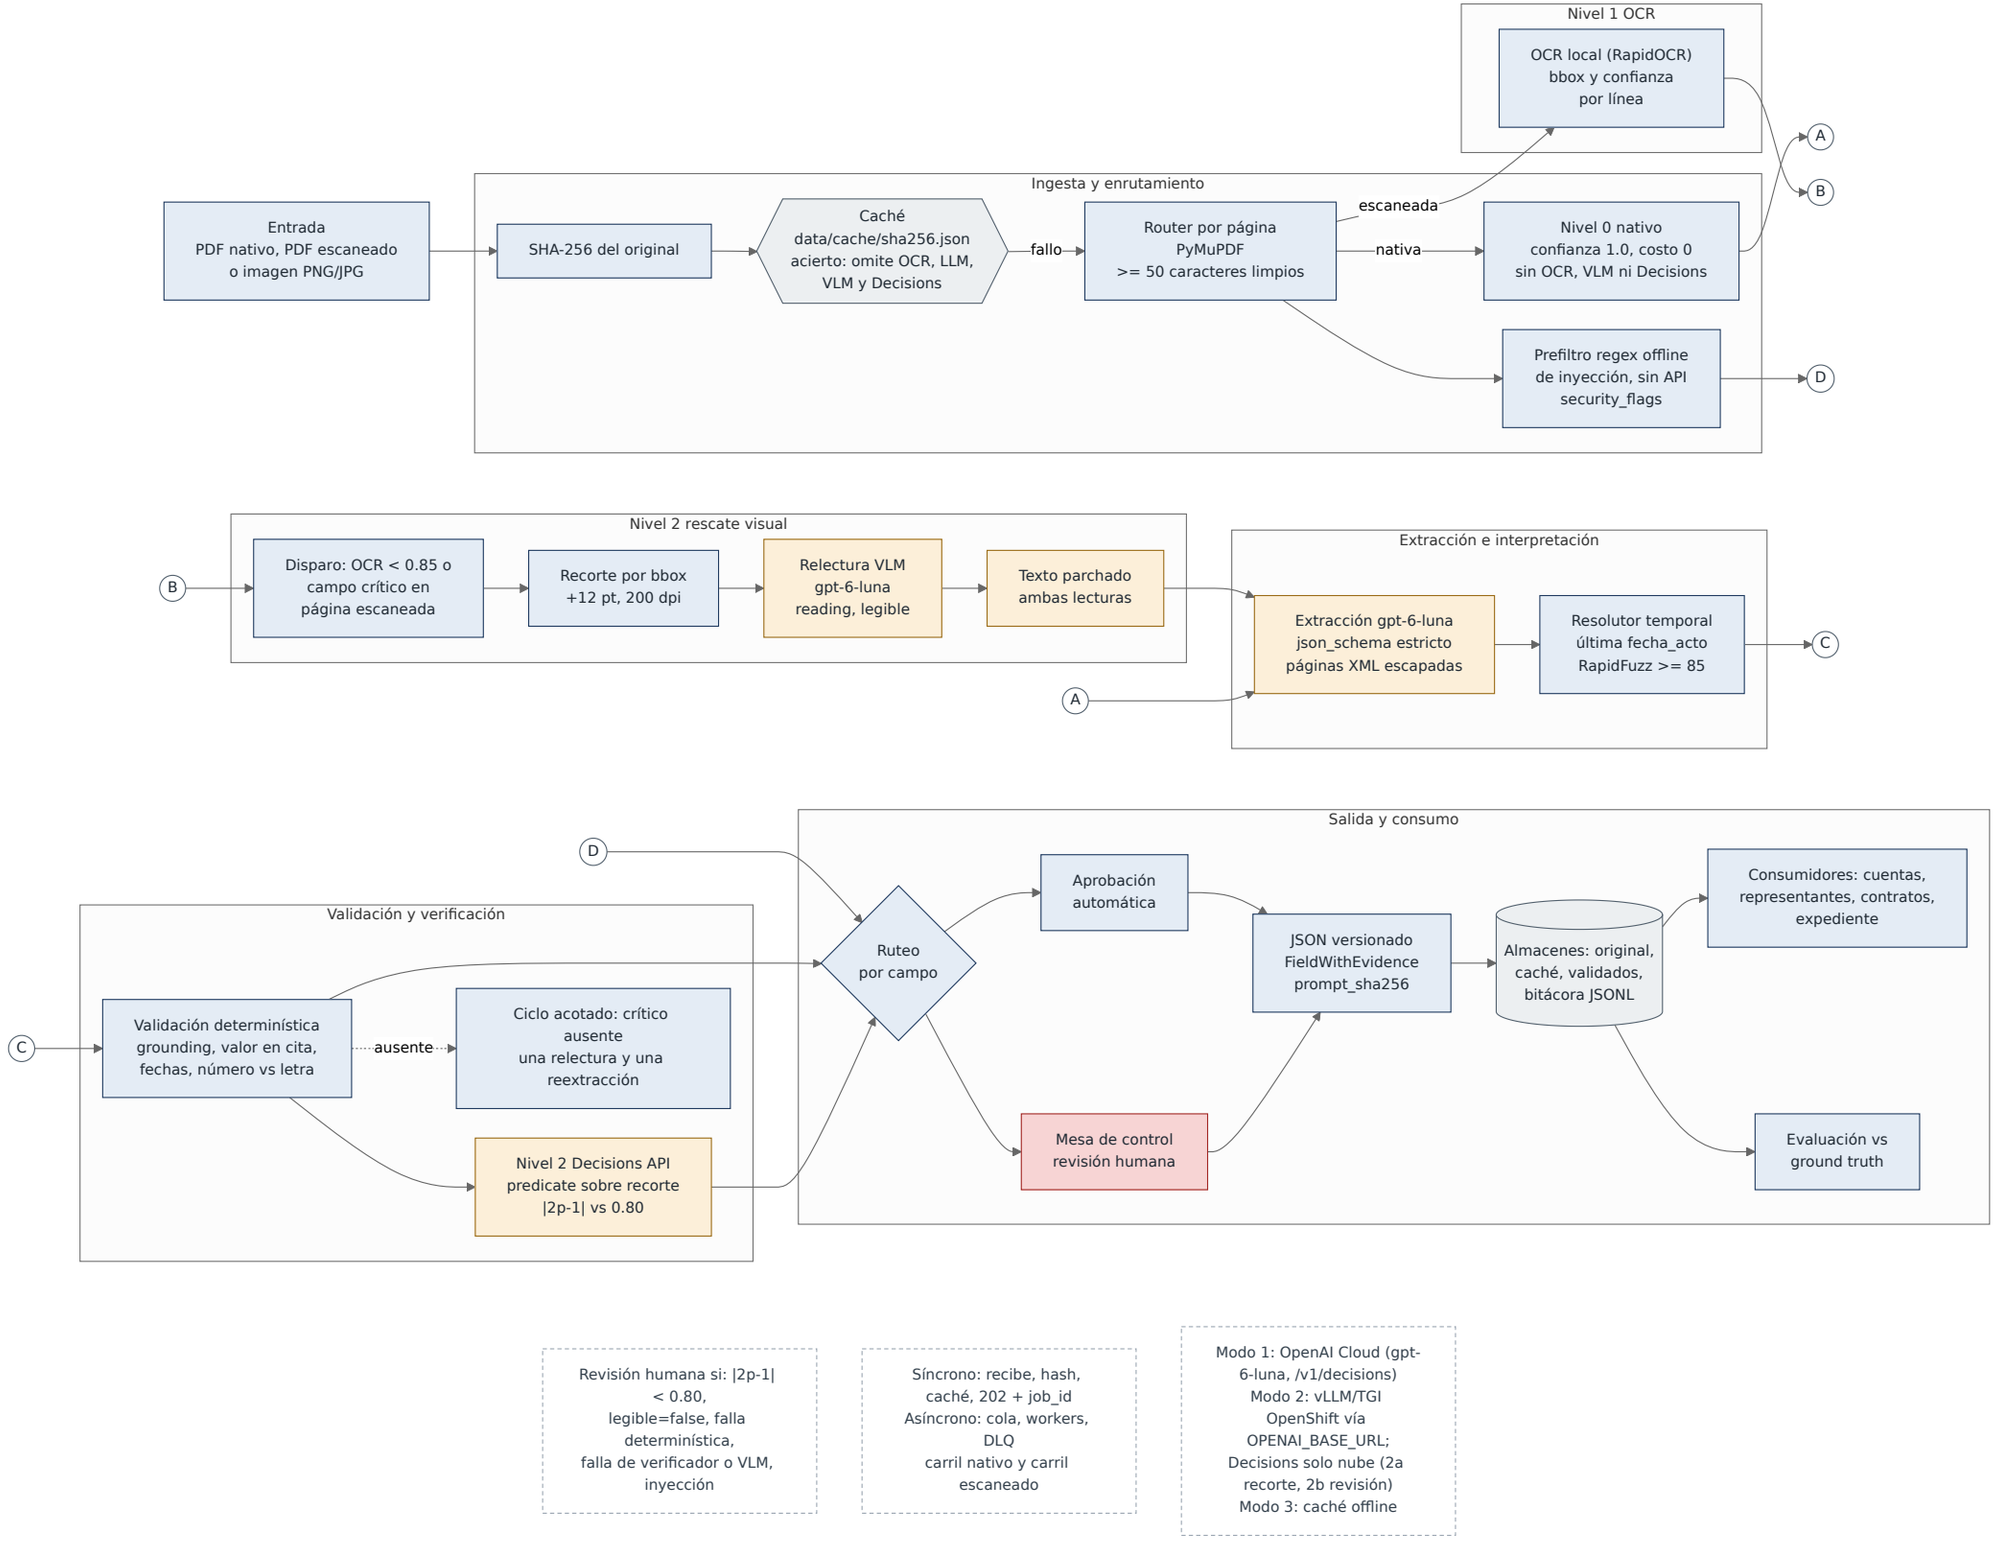
Nivel 1 OCR
OCR local (RapidOCR)
bbox y confianza
por línea
Ingesta y enrutamiento
Entrada
PDF nativo, PDF escaneado
o imagen PNG/JPG
SHA-256 del original
Caché
data/cache/sha256.json
acierto: omite OCR, LLM,
VLM y Decisions
fallo
Router por página
PyMuPDF
>= 50 caracteres limpios
escaneada
nativa
Nivel 0 nativo
confianza 1.0, costo 0
sin OCR, VLM ni Decisions
Prefiltro regex offline
de inyección, sin API
security_flags
A
B
D
Nivel 2 rescate visual
B
Disparo: OCR < 0.85 o
campo crítico en
página escaneada
Recorte por bbox
+12 pt, 200 dpi
Relectura VLM
gpt-6-luna
reading, legible
Texto parchado
ambas lecturas
Extracción e interpretación
A
Extracción gpt-6-luna
json_schema estricto
páginas XML escapadas
Resolutor temporal
última fecha_acto
RapidFuzz >= 85
C
Salida y consumo
D
Ruteo
por campo
Aprobación
automática
JSON versionado
FieldWithEvidence
prompt_sha256
Almacenes: original,
caché, validados,
bitácora JSONL
Consumidores: cuentas,
representantes, contratos,
expediente
Mesa de control
revisión humana
Evaluación vs
ground truth
Validación y verificación
C
Validación determinística
grounding, valor en cita,
fechas, número vs letra
ausente
Ciclo acotado: crítico
ausente
una relectura y una
reextracción
Nivel 2 Decisions API
predicate sobre recorte
|2p-1| vs 0.80
Revisión humana si: |2p-1|
< 0.80,
legible=false, falla
determinística,
falla de verificador o VLM,
inyección
Síncrono: recibe, hash,
caché, 202 + job_id
Asíncrono: cola, workers,
DLQ
carril nativo y carril
escaneado
Modo 1: OpenAI Cloud (gpt-
6-luna, /v1/decisions)
Modo 2: vLLM/TGI
OpenShift vía
OPENAI_BASE_URL;
Decisions solo nube (2a
recorte, 2b revisión)
Modo 3: caché offline

Decisiones de arquitectura

Respuestas a las preguntas de diseño; el diagrama está en la página anterior. Detalle en docs/ARCHITECTURE_AND_DESIGN.md.

1. PDF nativo frente a escaneado. Se decide por página: PyMuPDF extrae la capa de texto y cuenta caracteres alfanuméricos limpios. Con 50 o más la página es nativa (Nivel 0: confianza 1.0, costo 0, sin OCR, VLM ni Decisions); con menos se renderiza a 200 dpi y entra al OCR. Un documento puede ser híbrido. Las imágenes PNG/JPG se envuelven como páginas escaneadas y el SHA-256 se calcula sobre los bytes originales. Solo cambian la fuente del texto, su confianza y la posible escalación; extracción, interpretación y validación son las mismas.

2. Nativo, OCR, multimodal o LLM de texto. Nativo siempre que haya capa de texto: exacto, gratuito y determinístico. OCR local con bbox y confianza por línea (Nivel 1) para páginas escaneadas. Modelo multimodal solo sobre recortes físicos (+12 pt, 200 dpi) cuando una región tiene confianza OCR menor a 0.85, o siempre que un campo crítico (fecha, escritura, notario, capital, representantes, poderes) cae en una página escaneada; la relectura devuelve {reading, legible} y se conservan ambas lecturas. LLM de texto para la extracción a esquema estricto. La API Decisions (predicate) es el único verificador: evalúa el valor sobre el recorte y p se mapea a |2p-1| frente a 0.80.

3. Qué se conserva para auditoría. Original inmutable direccionado por SHA-256; extracción cruda en caché previa a la resolución (la lógica determinística se re-ejecuta siempre); JSON validado y versionado (schema_version, versiones de modelo, prompt_sha256) con page_number, source_quote, confidence_source, bbox y motivo de revisión por campo; recortes en outputs/crops/; lecturas OCR y VLM; y bitácora JSONL con PII enmascarada.

4. Síncrono y asíncrono. Síncrono: recepción, hash, consulta de caché y respuesta HTTP 202 con job_id (o el resultado si ya existe). Asíncrono: cola, workers y DLQ para OCR, VLM, extracción, verificación y revisión; carril rápido para páginas nativas y carril para páginas escaneadas. El prototipo corre por lotes desde la CLI.

5. Reglas, ML y GenAI. Reglas para todo lo verificable: enrutamiento, prefiltro de inyección por expresiones regulares sin API, grounding, valor en cita, número frente a letra, coherencia de fechas, resolución temporal y revocaciones (RapidFuzz >= 85 con guarda de apellidos). ML clásico para el OCR. GenAI solo para lenguaje o imagen no estructurados: extracción, relectura visual de recortes dudosos y verificación por predicado.

6. Agente o workflow. Workflow determinístico con puntos de IA acotados, no un agente. El orden de etapas, los umbrales y la decisión de revisión los fija el código; cada llamada a un modelo tiene entrada, esquema estricto y uso únicos, y el texto del documento se trata como dato no confiable. Un agente añadiría variabilidad y superficie de inyección difícil de auditar. Los ciclos son acotados: ante un campo crítico ausente en una página escaneada, una relectura VLM y a lo sumo una reextracción.

7. Revisión humana (Mesa de control). Por campo, cuando |2p-1| < 0.80; la región propia es legible = false; falla un chequeo determinístico (grounding, valor en cita, consistencia temporal, número frente a letra, spec del registro); falla el verificador o el VLM; o el prefiltro de inyección marcó la página. El revisor ve el recorte, la cita, la página, ambas lecturas y el motivo; el resto se aprueba automáticamente.

Modos de proveedor. Modo 1 (defecto): OpenAI Cloud, gpt-6-luna y /v1/decisions. Modo 2: vLLM/TGI en OpenShift vía OPENAI_BASE_URL para extracción y VLM; Decisions solo en la nube: 2a envía únicamente el recorte, 2b omite Decisions y manda a revisión humana. Modo 3: caché determinística sin conexión. El orquestador depende solo de interfaces (BaseLLMProvider, BaseOCRProvider, BaseVerifierProvider, BaseStorageRepository).

Reutilización y evolución. Se extrae una vez por documento; los consumidores (alta de cuentas, validación de representantes legales, firma y revisión de contratos, actualización de expediente) leen el mismo JSON y aplican su política sobre estado, evidencia y revisión. Un tipo documental nuevo se registra en DocumentRegistry sin tocar el orquestador. La evaluación contra ground truth mide aciertos, evidencia y falsos positivos críticos.