Arquitectura del pipeline de extracción de actas constitutivas

Workflow determinístico con pasos de IA acotados. Las páginas nativas omiten OCR, relectura VLM y Decisions.

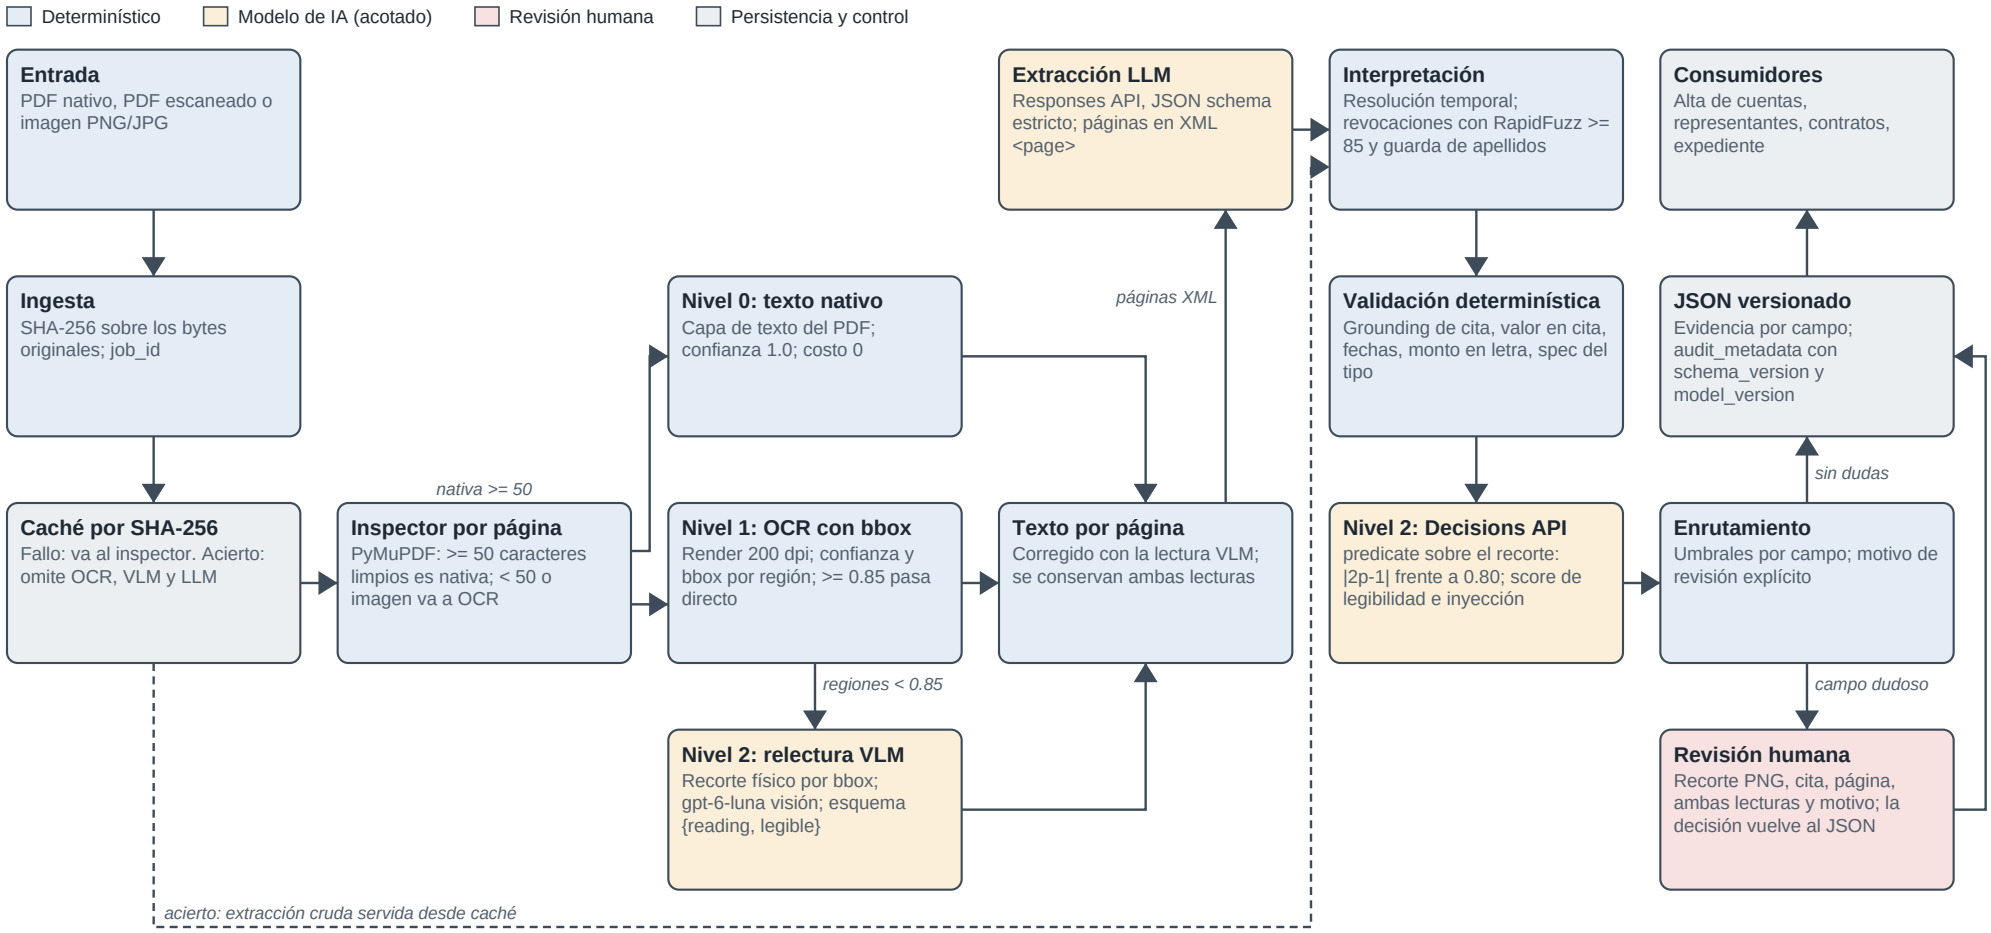

Capa transversal: todas las etapas persisten artefactos y registran eventos.

Almacenamiento por capas
Binario original (SHA-256); texto por página y fuente; regiones OCR con bbox y confianza; lecturas OCR y VLM; extracción cruda previa a la resolución (caché); JSON final con page_number, source_quote, confidence_source y motivo de revisión.

Bitácora de auditoría
JSON Lines con job_id, doc_sha256, stage, event, duration_ms y details; PIIRedactionFilter enmascara RFC, CURP y correo.

Evaluación y monitoreo
Métricas por campo contra ground truth, Evidence Hit Rate, falsos positivos críticos (revocados listados como activos) y tasa de revisión.

Producción: recepción síncrona (hash, caché, HTTP 202 con job_id); OCR, VLM, LLM, verificación y revisión asíncronas en cola con reintentos acotados y DLQ.
Prototipo: CLI por lotes (actas-cli). Reintentos tenacity solo para errores transitorios; rechazos y salidas fuera de esquema van a revisión.

Decisiones de arquitectura

Respuestas a las preguntas de diseño y criterios transversales. Detalle en docs/ARCHITECTURE_AND_DESIGN.md.

1. PDF nativo frente a escaneado. Se decide por página: PyMuPDF extrae la capa de texto y se cuentan caracteres alfanuméricos limpios. Con 50 o más la página es nativa (confianza 1.0); con menos se renderiza a 200 dpi y entra a OCR. Un documento puede ser híbrido. Una imagen PNG/JPG se trata como página escaneada. Solo cambia la fuente del texto y su confianza; extracción, resolución y validación son las mismas.

2. Nativo, OCR, multimodal o LLM de texto. Nativo siempre que haya capa de texto: exacto, gratuito y determinístico. OCR local con bbox (Nivel 1) para páginas sin texto, con confianza y bbox por región. Modelo multimodal solo sobre recortes con confianza OCR menor a 0.85 (relectura VLM con esquema {reading, legible}), nunca sobre el documento completo. LLM de texto para la extracción a esquema estricto sobre el texto corregido. Decisions (predicate) verifica el valor final sobre el mismo recorte y devuelve una probabilidad p que se mapea a |2p - 1|.

3. Qué se conserva. Original direccionado por SHA-256, texto por página con su fuente, regiones OCR con bbox y confianza, lecturas OCR y VLM, extracción cruda previa a la resolución (se cachea para re-ejecutar siempre la lógica determinística), JSON final con page_number, source_quote, confidence_source, bbox y motivo de revisión, audit_metadata (schema_version, model_version), prompt_sha256 en la entrada de caché y bitácora JSONL con PII enmascarada.

4. Síncrono y asíncrono. Síncrono: recepción, hash, consulta de caché y respuesta HTTP 202 con job_id (o el resultado si ya existe). Asíncrono: OCR, VLM, extracción, verificación y revisión humana, en cola con reintentos acotados y DLQ.

5. Reglas, ML y GenAI. Reglas para todo lo verificable: enrutamiento, grounding, valor en cita, número frente a letra, fechas, resolución temporal y revocaciones (RapidFuzz >= 85 con guarda de apellidos), umbrales. ML clásico para OCR y clasificación documental. GenAI solo para lenguaje no estructurado: extracción, relectura visual y verificación por predicado.

6. Agente o workflow. Workflow determinístico con pasos de IA acotados. El orden de etapas, los umbrales y la decisión de revisión los fija el código; cada llamada a un modelo tiene entrada, esquema y uso definidos. Un agente autónomo añade variabilidad y superficie de inyección difícil de auditar, sin beneficio para un documento de estructura conocida.

7. Revisión humana. Decisions calibrado menor a 0.80; VLM declara la región ilegible; OCR y VLM discrepan sin confirmación alta de Decisions; falla el grounding (confianza topada en 0.40); el valor no está en su cita; incoherencia temporal; revocación ambigua (similitud 75 a 85 o apellidos distintos); campo requerido ausente; verificador no disponible o con rechazo; legibilidad o riesgo de inyección fuera de umbral (preguntas score). El revisor ve el recorte guardado en outputs/crops/{acta_id}_p{page}_{field}_bbox.png, la cita, ambas lecturas y el motivo.

Por qué la API Decisions. POST /v1/decisions devuelve por pregunta una probability (predicate) o un score con confidence (score, choice); es la primitiva diseñada para esta tarea y solo factura entrada (USD 0.10 por millón). Una confianza verbalizada por un modelo generativo no se usa para decidir, y no se usan modelos de razonamiento extendido. Extracción y VLM pueden ir a un servidor on-prem compatible con OpenAI (OPENAI_BASE_URL); Decisions requiere OpenAI Cloud; sin conexión se usa la caché determinística.

Reutilización y evolución. Se extrae una vez por documento; los consumidores (alta de cuentas, validación de representantes, firma de contratos, expediente) leen el mismo JSON versionado y aplican su política sobre status, evidencia y revisión. Un tipo documental nuevo se agrega registrando un DocumentTypeSpec en DocumentRegistry, sin tocar el orquestador.

Fallos, reintentos e idempotencia. Reintentos con tenacity (tres intentos y backoff exponencial) solo para errores transitorios; el SDK usa max_retries=0. Rechazos, salidas fuera de esquema o verificador no disponible van a revisión con motivo. Un resultado con fallas de grounding no se cachea. Un cambio de prompt (prompt_sha256) invalida entradas vivas.

Privacidad, observabilidad y costo. PIIRedactionFilter en consola y bitácora; extracción con store=False. Costo variable concentrado en páginas escaneadas y extracción LLM: una verificación Decisions usó 867 tokens de entrada (USD 0.10 por millón); la extracción del Acta A usó 5,087 tokens de entrada y 5,101 de salida. Escalado horizontal con workers sin estado detrás de la cola.